

Progetto 6: Valutazione e Fine-Tuning di Modelli Linguistici (LLM)

Gruppo di Progetto

26 febbraio 2026

1 Introduction

1.1 Problem Description

Il **Progetto 6: Valutazione e Fine-Tuning di Modelli Linguistici (LLM)** ha come obiettivo principale l'analisi comparativa di modelli linguistici pre-addestrati, valutandone le capacità di adattamento a task specifici. Il focus del lavoro risiede nell'esecuzione pratica di diverse strategie di **Fine-Tuning** su modelli distinti, al fine di misurarne quantitativamente le prestazioni post-adattamento e farne emergere, tramite confronto diretto, i rispettivi **punti di forza e di debolezza**.

Nello specifico, il nostro gruppo ha selezionato il task di **Emotion Recognition** (Classificazione delle Emozioni) applicato a testi brevi provenienti dai social media. La rilevanza di questo problema è elevata nell'attuale panorama digitale: la capacità di analizzare automaticamente il "sentiment" e le sfumature emotive (gioia, tristezza, rabbia, ecc.) su piattaforme come Twitter è cruciale per applicazioni di monitoraggio della brand reputation, analisi sociale e customer care automatizzato.

Il pubblico di riferimento include ricercatori NLP, data scientist e sviluppatori di assistenti virtuali empatici. Una soluzione efficace permette di automatizzare l'analisi di grandi moli di dati non strutturati (Big Data) con costi ridotti rispetto all'annotazione manuale.

1.2 Proposed Solution

Per affrontare il problema, abbiamo adottato un **approccio sperimentale comparativo**, testando diverse tecniche di fine-tuning su una selezione eterogenea di modelli pre-addestrati. L'obiettivo centrale è stato confrontare l'efficacia delle diverse strategie di adattamento in relazione alle architetture sottostanti.

La nostra soluzione si articola nei seguenti punti:

- **Modelli Selezionati:** Abbiamo condotto esperimenti su quattro architetture distinte per valutare l'impatto della dimensione e della specializzazione del pre-training:
 - `vinai/bertweet-base`: Modello domain-specific per Twitter.
 - `distilbert/distilbert-base-uncased`: Modello distillato (leggero) per testare l'efficienza.
 - `google-bert/bert-base-uncased`: La baseline standard per il NLP.

– FacebookAI/roberta-base: Versione ottimizzata di BERT.

- **Approccio Metodologico:** Un confronto sistematico tra diverse metodologie di apprendimento:
 1. **Transfer Learning (Frozen):** Addestramento del solo classificatore mantenendo il corpo del modello congelato.
 2. **Complete Fine-Tuning:** Aggiornamento di tutti i pesi del modello per l'adattamento al task. Si specifica inoltre che, su alcuni modelli, si è scelto di utilizzare anche **LoRA (Low-Rank Adaptation)**, una tecnica PEFT che inietta matrici addestrabili nei layer del modello.
 3. **In-Context Learning (Zero/Few-Shot):** Per testare le capacità native senza alcun aggiornamento dei pesi.
- **Sfide Computazionali:** Le principali difficoltà affrontate sono state la gestione della **Context Window** limitata (tipica dei modelli Encoder-Only), che ha imposto vincoli severi sulle strategie di Few-Shot Learning, e la sfida di massimizzare le performance di generalizzazione nonostante il **basso numero di parametri** dei modelli “base” e “distilled” selezionati, richiedendo un’ottimizzazione fine degli iperparametri.

Task Distribution: Il lavoro è stato parallelizzato assegnando a ciascun membro del gruppo la responsabilità completa di una specifica architettura. Ogni componente ha curato l’analisi esplorativa, il pre-processing, il fine-tuning e la valutazione del proprio modello, per poi convergere in una fase finale di confronto dei risultati.

- **[Membro 1]:** Responsabile per `vinai/bertweet-base`.
- **[Membro 2]:** Responsabile per `distilbert/distilbert-base-uncased`.
- **[Membro 3]:** Responsabile per `google-bert/bert-base-uncased`.
- **[Membro 4]:** Responsabile per FacebookAI/roberta-base.

Summary of Achieved Results: TODO

1.3 [extra] Literature Review

In letteratura, il benchmark per il riconoscimento delle emozioni su testo fa spesso riferimento al dataset `dair-ai/emotion`, introdotto originariamente da Saravia et al. (2018)[1] nel lavoro “CARER: Contextualized Affect Representations for Emotion Recognition”. Questo dataset è stato costruito utilizzando hashtag come etichette deboli (distant supervision) per classificare i tweet in categorie emotive fondamentali.

Per quanto riguarda i modelli, lo stato dell’arte su dati provenienti da Twitter è rappresentato da architetture domain-specific come **BERTweet**, presentato da Nguyen et al. (2020) [2]. **BERTweet** utilizza la stessa architettura di BERT-base ma è stato pre-addestrato su un corpus massivo di 850 milioni di tweet inglesi, dimostrando prestazioni superiori rispetto a RoBERTa e XLM-R su task di classificazione testuale, POS tagging e NER in ambito social media.

Tuttavia, approcci di Full Fine-Tuning su questi modelli richiedono risorse computazionali significative. Per mitigare questo problema, Hu et al. (2021) [3] hanno proposto **LoRA (Low-Rank Adaptation)**. Questa tecnica congela i pesi del modello pre-addestrato e inietta matrici di decomposizione di rango ridotto nei layer del Transformer, riducendo drasticamente il numero di parametri addestrabili (fino a 10.000 volte in meno rispetto al fine-tuning completo su GPT-3) senza introdurre latenza in inferenza. Il nostro lavoro dimostra come l'applicazione di LoRA su BERTweet, se ben calibrata, possa eguagliare i metodi tradizionali a una frazione del costo computazionale.

2 Proposed Method

2.1 Solution Choice

Abbiamo scartato l'uso di LLM generativi generalisti (es. GPT-4, Llama-3) per motivi di latenza in inferenza e costi computazionali, preferendo architetture **Encoder-Only** (come BERTweet e le varianti di BERT/RoBERTa). I modelli Encoder sono strutturalmente superiori nei task di classificazione pura grazie all'attenzione bidirezionale che cattura l'intero contesto della frase simultaneamente.

Per quanto riguarda le tecniche di addestramento e adattamento, abbiamo optato per un confronto a tutto tondo al fine di comprendere appieno i trade-off tra risorse impiegate e prestazioni ottenute. Inizialmente abbiamo valutato il **Transfer Learning** classico (approccio *Feature Extraction*), che pur essendo computazionalmente leggero e veloce presenta lo svantaggio di congelare il corpo del modello, limitandone drasticamente la capacità di apprendimento su domini complessi. Successivamente, per stabilire un limite superiore (*upper bound*) alle performance, abbiamo testato il **Complete Fine-Tuning**, il quale aggiorna la totalità dei pesi garantendo un'ottima accuratezza, ma risultando al contempo lento e molto oneroso in termini di memoria. Per avere un quadro sperimentale completo, abbiamo esplorato anche l'**In-Context Learning** per testare le capacità native (*zero-shot* e *few-shot*) dei modelli senza effettuare alcun aggiornamento dei pesi, scontrandoci tuttavia con i severi limiti imposti dalla *context window* ristretta tipica di queste architetture.

Infine, proprio per superare l'inefficienza e i costi del fine-tuning completo e la rigidità del transfer learning classico, su alcuni modelli si è scelto di implementare **LoRA (Low-Rank Adaptation)**. Questa tecnica permette di adattare efficacemente le rappresentazioni interne del modello al task specifico delle emozioni iniettando e modificando solo poche matrici di peso aggiuntive.

2.2 Methodology for performance measurement

Le prestazioni sono state valutate utilizzando un set di metriche standard per la classificazione multiclasse, selezionate per fornire una visione sia quantitativa che qualitativa:

- **Accuracy:** Rappresenta la frazione di predizioni corrette rispetto al totale dei campioni. Sebbene sia la metrica più intuitiva per una valutazione globale, in questo progetto viene utilizzata solo come riferimento di base, poiché può risultare ingannevole in presenza di dataset sbilanciati (un modello che predice sempre la classe maggioritaria avrebbe comunque un'accuratezza elevata).

- **Macro F1-Score:** È la media armonica tra *Precision* e *Recall*, calcolata indipendentemente per ogni classe e poi mediata (senza pesare per la numerosità delle istanze). Questa è la metrica **critica** per il nostro task a causa del forte sbilanciamento del dataset (le classi *Joy* e *Sadness* sono molto più frequenti di *Surprise* e *Love*). L'uso del *Macro-average* penalizza i modelli che ignorano le classi minoritarie, garantendo che ogni emozione abbia lo stesso peso nella valutazione finale.
- **Confusion Matrix:** È una tabella che visualizza il confronto tra le etichette reali (righe) e quelle predette dal modello (colonne). Viene utilizzata per l'**analisi qualitativa** degli errori, permettendo di diagnosticare non solo *quanto* il modello sbaglia, ma *dove* sbaglia (ad esempio, rivelando se l'emozione *Love* viene sistematicamente confusa con *Joy* a causa della sovrapposizione semantica).

3 Experimental Results

3.1 bertweet-base

3.1.1 Demonstration and Technologies

Per garantire la riproducibilità degli esperimenti, il progetto è stato sviluppato utilizzando le seguenti tecnologie e versioni:

- **Environment:** Ambiente di sviluppo locale (Python 3.13.12).
- **Librerie:**
 - `transformers` (HuggingFace) per la gestione del modello BERTweet.
 - `peft` (HuggingFace) per l'implementazione di LoRA.
 - `datasets` e `evaluate` per la gestione dei dati e delle metriche.
 - `scikit-learn` per il calcolo delle matrici di confusione.
- **Istruzioni Demo:** Il notebook fornito esegue automaticamente il download del dataset, il caricamento dei pesi LoRA ottimizzati e la valutazione sul validation set, stampando sul notebook le metriche finali.

3.1.2 Results

La configurazione migliore identificata (**LoRA Optimized**) ha ottenuto i seguenti risultati sul Validation Set (Best Epoch):

- **Accuracy:** 94.20%
- **Macro F1-Score:** 91.69%
- **Training Time:** ~15 minuti (10 epoche).

Questa configurazione utilizzava un Rango $r = 8$, un Learning Rate di $2e^{-4}$ con *Cosine Scheduler*, e applicava LoRA a **tutti i layer lineari** del trasformatore (*query*, *key*, *value*, *dense*), non solo a quelli di attenzione.

3.1.3 Ablation Study: Analysis of Configurations

Lo studio di ablation è stato condotto in tre fasi distinte per isolare l’impatto dei singoli iperparametri e delle limitazioni architetturali.

3.1.4 1. Impatto del Context Window (In-Context Learning)

Abbiamo valutato l’efficacia dell’aggiunta di esempi (k -shot) nel prompt. I risultati mostrano che aumentare k non migliora le prestazioni a causa della limitata finestra di contesto di BERTweet (128 token). Con $k = 5$, il modello inizia a troncare il prompt, perdendo informazioni cruciali.

Shots (k)	Accuracy	Truncated	Note
0	49.30%	0	Baseline Zero-Shot (Migliore).
1	46.87%	0	Nessun miglioramento significativo.
3	48.40%	0	Inizio saturazione contesto.
5	48.88%	25	Degrado tecnico: 25 esempi su 2000 troncati.

Tabella 1: Ablation su In-Context Learning

3.1.5 2. Tuning del Transfer Learning (Frozen)

Mantenendo il corpo del modello congelato, abbiamo condotto una *Grid Search* completa combinando tre valori di Learning Rate ($LR \in \{1e^{-3}, 1e^{-4}, 1e^{-5}\}$) con due dimensioni di Batch Size ($BS \in \{8, 16\}$), per un totale di 6 configurazioni sperimentali. I risultati indicano che un LR più aggressivo ($1e^{-3}$) è strettamente necessario per addestrare efficacemente la testa di classificazione da zero; tuttavia, l’accuracy massima rimane bloccata attorno al 54%, confermando l’insufficienza del metodo *Frozen* per questo task.

Learning Rate	Batch Size	Accuracy	F1-Score
$1e^{-3}$	16	54.45%	29.9%
$1e^{-4}$	16	50.25%	20.8%
$1e^{-5}$	16	40.85%	14.9%

Tabella 2: Sensibilità al Learning Rate nel Transfer Learning (Batch Size fissato a 16)

3.1.6 3. Configurazione Ottimale di LoRA

Per individuare l’architettura PEFT ideale, abbiamo eseguito una *Grid Search* estensiva testando 36 combinazioni diverse di iperparametri: Rango ($r \in \{8, 16, 32\}$), Moduli Target (solo attenzione vs tutti i layer lineari), Learning Rate ($1e^{-3}, 1e^{-4}, 1e^{-5}$) e Batch Size (8, 16). I dati dimostrano che targettare **tutti i moduli lineari** (all-linear) con un rango contenuto ($r = 8$) è nettamente più efficace che aumentare il rango su pochi moduli. È emerso inoltre un trade-off critico sulla stabilità: LR elevati ($1e^{-3}$), pur funzionando su configurazioni semplici, causano *Training Collapse* quando applicati a modelli più complessi ($r \geq 16$ su tutti i layer).

Rango	Target Modules	LR	Acc	Esito
8	[q, v]	$1e^{-3}$	92.35%	Buon risultato base.
8	[q, v, k, dense]	$2e^{-4}$	94.20%	Migliore (Stabile).
16	[q, v, k, dense]	$1e^{-3}$	34.75%	<i>Training Collapse</i> (LR troppo alto).
32	[q, v]	$1e^{-4}$	91.75%	Aumentare r non aiuta quanto targettare dense .

Tabella 3: Selezione della configurazione LoRA ottimale tramite Grid Search

3.1.7 Sintesi Finale e Confronto

Il grafico seguente riassume il salto prestazionale ottenuto passando attraverso le diverse strategie.




Figura 1: Confronto visivo delle Accuracy tra le strategie testate. Si nota il netto divario tra i metodi Frozen e LoRA.

In conclusione, la tabella riassuntiva delle migliori configurazioni per categoria è la seguente:

Strategia	Accuracy	F1	Conclusioni
In-Context ($k = 0$)	49.30%	24.6%	Inadatto per task emotivi specifici.
Transfer Learning	54.45%	29.9%	Limitato dalle feature pre-addestrate.
LoRA Base	92.35%	87.5%	Ottimo, ma migliorabile.
LoRA Optimized	94.20%	91.7%	Best Model. Estensione ai layer densi + LR controllato.

Tabella 4: Riepilogo finale Ablation Study

3.1.8 Results Discussion

I risultati ottenuti hanno ampiamente superato le aspettative iniziali per un approccio basato su PEFT. Aver raggiunto un'accuratezza del 94.20% dimostra che i modelli pre-addestrati su domini specifici (come BERTweet per i testi provenienti dai social media) costituiscono una base eccellente per il fine tuning, richiedendo l'aggiornamento di una frazione minima di parametri per adattarsi a task complessi. Inoltre, l'elevato Macro F1-Score (91.69%) è un indicatore cruciale: conferma che il modello non è collassato sulle classi maggioritarie (come *Joy* o *Sadness*), ma ha imparato a discriminare con efficacia anche le emozioni meno frequenti nel dataset.

Tuttavia, l'analisi qualitativa degli errori, supportata dalla Matrice di Confusione (Figura 2), ha rivelato che la maggior parte delle misclassificazioni residue non è casuale, ma si concentra su specifiche coppie di emozioni semanticamente vicine o contestualmente ambigue:

1. **Love vs Joy:** Questa rappresenta la confusione più frequente. È dovuta alla forte sovrapposizione semantica nei testi brevi tipici dei social network, dove parole di affetto, forte apprezzamento ed entusiasmo vengono usate in modo intercambiabile. Frasi che esprimono una profonda gioia spesso contengono termini legati all'amore (es. "I absolutely love this!"), rendendo il confine decisionale estremamente sfumato, a volte anche per un annotatore umano.
2. **Surprise vs Fear:** Nei tweet, che sono intrinsecamente brevi e spesso privi di un contesto esteso, la reazione a un evento scioccante può essere facilmente confusa dal modello: non avendo abbastanza indizi testuali, risulta difficile disambiguare se la sorpresa sia di natura neutra/positiva oppure legata a una minaccia (paura).




Figura 2: Matrice di Confusione del modello LoRA.

3.1.9 Method Validity

Il metodo LoRA si è dimostrato estremamente valido e robusto. Al contrario, lo studio di ablation su **In-Context Learning** ha evidenziato un limite strutturale critico: l'architettura BERTweet, progettata con una finestra di contesto ridotta (128 token), **non è idonea** a strategie Few-Shot ($k > 3$). Gli esempi dimostrativi tendono a saturare la memoria e troncare il prompt, peggiorando le performance invece di migliorarle, rendendo il fine-tuning una scelta obbligata per questo tipo di architetture.

3.2 distilbert-base-uncased

3.3 bert-base-uncased

3.4 roberta-base

3.5 Limitations and Maturity

- **Limiti:** La *Context Window* limitata impedisce l'uso di prompt complessi o catene di ragionamento. Il dataset presenta un sbilanciamento naturale che penalizza leggermente le classi minoritarie (*Surprise*).
- **Maturità:** La soluzione sviluppata, basata su librerie standard industriali (**transformers**, **peft**), ha raggiunto un buon livello di maturità tecnologica, pronta per essere integrata in pipeline di produzione con costi di inferenza contenuti.

3.6 Future Works

Per avanzare ulteriormente nel progetto e superare i limiti identificati, proponiamo le seguenti direzioni di ricerca:

1. **Data Augmentation via Back-Translation:** Per mitigare lo sbilanciamento delle classi (in particolare *Surprise*, che ha pochi campioni), proponiamo di generare dati sintetici utilizzando una pipeline di traduzione andata-ritorno (es. Inglese $\rightarrow$ Francese $\rightarrow$ Inglese). Questa tecnica introduce variazioni lessicali e sintattiche naturali mantenendo inalterata la semantica originale, arricchendo il training set con esempi diversificati che rendono il modello più robusto sulle classi minoritarie.
2. **Supervised Contrastive Learning:** Per risolvere l'ambiguità tra classi semanticamente sovrapposte come *Love* e *Joy*, suggeriamo di introdurre una fase preliminare di addestramento con *SupCon Loss*. A differenza della classica Cross-Entropy (che valuta i campioni singolarmente), la loss contrastiva lavora su coppie: forza l'encoder ad avvicinare drasticamente le rappresentazioni vettoriali dei tweet della stessa classe e ad allontanare quelle di classi diverse nello spazio latente. Questo creerebbe confini decisionali più netti prima ancora di addestrare il classificatore finale.
3. **Task-Adaptive Pre-Training:** Invece di passare direttamente dal modello generico (BERTweet) al fine-tuning, proponiamo una fase intermedia di "riscaldamento". Questa consiste nel continuare il pre-training con obiettivo *Masked Language Modeling* (MLM) utilizzando i soli testi del dataset **emotion** (senza etichette). Questo adatta i pesi dell'encoder allo specifico vocabolario, slang e distribuzione linguistica

del nostro dataset, ottimizzando la capacità del modello di estrarre feature rilevanti da contesti emotivi ambigui prima di applicare LoRA.

References

- [1] E. Saravia, H.-C. T. Liu, Y.-H. Huang, J. Wu e Y.-S. Chen, “CARER: Contextualized Affect Representations for Emotion Recognition,” in *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, Brussels, Belgium: Association for Computational Linguistics, ott. 2018, pp. 3687–3697. DOI: [10.18653/v1/D18-1404](https://doi.org/10.18653/v1/D18-1404) indirizzo: <https://www.aclweb.org/anthology/D18-1404>
- [2] D. Q. Nguyen, T. Vu e A. Tuan Nguyen, “BERTweet: A pre-trained language model for English Tweets,” in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, Q. Liu e D. Schlangen, cur., Online: Association for Computational Linguistics, ott. 2020, pp. 9–14. DOI: [10.18653/v1/2020.emnlp-demos.2](https://doi.org/10.18653/v1/2020.emnlp-demos.2) indirizzo: <https://aclanthology.org/2020.emnlp-demos.2/>
- [3] E. J. Hu et al., “LoRA: Low-Rank Adaptation of Large Language Models,” *CoRR*, vol. abs/2106.09685, 2021. arXiv: [2106.09685](https://arxiv.org/abs/2106.09685). indirizzo: <https://arxiv.org/abs/2106.09685>